

Proposta di Project Work: Fundamentals of Machine Learning

Studente: Youness Aharram Matricola: 7198778

Previsione della tossicità molecolare tramite Graph Isomorphism Networks

Descrizione problema

L'obiettivo del progetto è studiare come applicare il Deep Learning a dati non strutturati, come le molecole. Invece di utilizzare caratteristiche definite manualmente, le molecole vengono rappresentate direttamente come grafi:

- I nodi rappresentano gli atomi
- Gli archi rappresentano i legami chimici

In questo modo, il modello è in grado di apprendere automaticamente le informazioni più rilevanti. Per l'addestramento verrà utilizzato il dataset pubblico **Tox21**, in cui per ogni molecola è necessario prevedere diversi tipi di tossicità contemporaneamente (12 in totale). Si tratta quindi di un problema di classificazione *multi-task* e *multi-label*. Il modello utilizzato sarà una Graph Neural Network (GNN), in particolare una Graph Isomorphism Network (GIN), scelta per la sua capacità di distinguere strutture di grafi differenti. Attraverso il meccanismo di *message passing*, il modello combina le informazioni provenienti dai nodi per costruire una rappresentazione compatta dell'intera molecola. Questa rappresentazione viene poi utilizzata per predire i diversi tipi di tossicità.

Verifica Iniziale delle Competenze

Per affrontare questo progetto, parto dalle seguenti competenze iniziali:

- **NumPy, Pandas:** Buona padronanza del linguaggio e delle librerie standard per l'analisi dati.
- **Fondamenti di Machine Learning:** Comprensione del ciclo di vita di un modello (train/ validation/ test split), concetti di overfitting/underfitting, e utilizzo di metriche di valutazione di base.
- **Basi di Deep Learning:** Conoscenza teorica del funzionamento delle reti neurali (MLP e CNN).

Obiettivi di Apprendimento

1. Teoria delle Graph Neural Networks

Comprendere i fondamenti matematici delle Graph Neural Networks, con particolare attenzione al paradigma del *message passing* e alla teoria dell'espressività delle Graph Isomorphism Networks (GIN).

2. Utilizzo di PyTorch Geometric (PyG)

Acquisire autonomia nell'utilizzo della libreria *PyTorch Geometric*, imparando a gestire strutture dati basate su grafi, inclusi nodi, archi e feature, e a sfruttare i *DataLoader* per il processamento efficiente di più grafi disconnessi.

3. Architettura e Graph Pooling

Progettare una pipeline completa che parta da rappresentazioni a livello di nodo (ottenute tramite layer convoluzionali su grafi) e arrivi a una rappresentazione globale del grafo, utilizzando tecniche di *global pooling* per effettuare classificazione a livello di intera molecola.

4. Gestione di task multi-label sbilanciati

Sviluppare competenze nella valutazione di modelli applicati a dati reali, in particolare in contesti medici, utilizzando metriche più robuste dell'accuratezza, come la *ROC-AUC*, calcolata separatamente sui diversi target.